

Algoritmos y Estructuras de Datos

Tema 3: Complejidad Algorítmica

Grado Imat. Escuela ICAI

Juan C. Aguí García



- Un algoritmo debe funcionar en todos los casos del problema que manifiesta resolver.
- Para demostrar que un algoritmo es incorrecto, basta encontrar un ejemplo en el que no funcione.
- **Dominio de definición del algoritmo** → conjunto de casos que debe considerarse
- **Principio de invarianza:** Dos implementaciones distintas del mismo algoritmo no diferirán en su eficiencia¹ en más de alguna constante multiplicativa (10 veces más deprisa... etc).

¹Aunque no sabemos aún con precisión qué es la eficiencia

- Se debe considerar el caso peor de un algoritmo, tamaño y condiciones, para los que el algoritmo requiera más tiempo
 - Hay que analizar el caso peor en procesos donde los tiempos de respuesta sean críticos (centrales nucleares, coche autoconducido, etc.) y para asegurar la terminación del mismo en tiempo razonable.
 - Por ejemplo, el tiempo requerido por el algoritmo de inserción, oscila entre n y n^2 , en función de los datos aportados al algoritmo
- Hay que evaluar el comportamiento medio de un algoritmo (A veces se denomina valor *amortizado*) donde el coste de operaciones particulares se ha da distribuir sobre varias llamadas al algoritmo.

Part I

Notación Asintótica The big O

ver https://www.youtube.com/watch?v=Q_1M2JaijjQ

- Permite comparar de forma genérica y abstracta los recursos demandados por un algoritmo en función del volumen de datos a procesar
 - Independientemente de los datos concretos a procesar
 - Independientemente del lenguaje de programación
 - Independientemente del ordenador que lo ejecute
- Considerar dos recursos básicos:
 - Tiempo de ejecución
 - Consumo de memoria²
- La medida del volumen de los datos depende del problema:
 - Algoritmos de ordenación; número de registros a ordenar
 - Árboles binarios de búsqueda: número de nodos
 - Grafos: número de vértices, número de conexiones ? La suma ?

²Existen algoritmos "*out of core*" que funcionan con los datos en memoria y en almacenamiento externo



- **Cota asintótica Superior (The big O).**

Se dice que $f(n) = O(g(n))$ si:

$$\exists c, N_0 \mid \forall N \geq N_0 \quad 0 \leq f(n) \leq c * g(N)$$

- **Cota asintótica Inferior (The big Ω)**

Se dice que $f(n) = \Omega(g(n))$ si:

$$\exists c, N_0 \mid \forall N \geq N_0 \quad 0 \leq c * g(n) \leq f(n)$$

- **Cota asintótica Superior e Inferior (The big Θ)**

Se dice que $f(n) = \Theta(g(n))$ si:

$$\exists c_1, c_2, N_0 \mid \forall N \geq N_0 \quad 0 \leq c_1 * g(n) \leq f(n) \leq c_2 * g(n)$$

Where N is the size indicator of the algorithm, and $N_0, c, c_1, c_2 > 0$. Si se dan las cotas inferior y superior, se puede derivar la existencia de c_1 y c_2 que demuestra la Cota Θ



Cotas Asintóticas: Visual




Figure: Visualización Cotas Asintóticas ©Cormen et al.

- Sólo nos preocupa el "**comportamiento asintótico**" esto es, para n grandes. En valores pequeños de n , esto es algoritmos ejecutando sobre datos pequeños, pueden ocurrir cosas raras, que no afectan a nuestras conclusiones.
- Las cotas Superior (O), y la cota Inferior (Ω) no presuponen una evolución **paralela**, pudiendo crecer, sin embargo, $f(n)$ y $g(n)$ a **ritmos muy dispares**.
- Sólo la cota Inferior y Superior asegura un orden de crecimiento asintótico parejo entre el coste del algoritmo $f(n)$ y la función $g(n)$ a expensas de constantes fijas.


Rangos de Crecimiento

A partir de un n suficientemente grande se cumple que:

$$\log \log n < \log n < n < n * \log n < n^2 < n^3 < c^n$$

Diferentes Rangos:

- 1 Logarithmic
(\log , $\log \log$)
- 2 Polynomial
(n^a ; $a > 0$)
- 3 Pol-logarithmic
($n^a * \log^b(n)$; $a, b > 0$)
- 4 Exponential
(c^n ; $c > 1$)



El Orden de Crecimiento es importante

Para un tamaño realista de datos, el orden de crecimiento de un algoritmo marca la diferencia y su usabilidad práctica, o no

Hay:

- 10^{80} átomos en el universo.
- $4,4 \times 10^{17}$ segundos, desde el BigBang

No es difícil pensar algoritmos que sobrepasan estos límites. Si para $n = 1$ el tiempo es de $10\mu s$, para $n = 1,000,000$ los tiempos de cálculo esperables son:

logarithmic 60 ms

linear 10 segundos

square 115 días

cubic 3,174 siglos

exponential mayor que bigbang

$$c * \mathbf{O}(f(N)) = \mathbf{O}(f(N)) \quad c > 0 \text{ cte} \quad (1)$$

$$\mathbf{O}(f(N) + g(N)) = \max(\mathbf{O}(f(N)), \mathbf{O}(g(N))) \quad (2)$$

$$\mathbf{O}(f(N)) + \mathbf{O}(g(N)) = \mathbf{O}(f(N) + g(N)) \quad (3)$$

$$\mathbf{O}(f(N)) \times \mathbf{O}(g(N)) = \mathbf{O}(f(N) \times g(N)) \quad (4)$$

$$\mathbf{O}(\mathbf{O}f(N)) = \mathbf{O}(f(N)) \quad (5)$$

- (1) Órdenes son independientes de constantes
- (2) Órdenes de suma de dos funciones es el máximo de los respectivos órdenes
- (3) Suma de órdenes igual al orden de la suma de las funciones³
- (4) Orden del producto igual al producto de los respectivos órdenes
- (5) Orden del Orden equivale al Orden

Propiedades Notación Asintótica: Ejemplos

$$3 * \mathbf{O}(N^3) = \mathbf{O}(N^3)$$

$$\mathbf{O}(N^2 + N) = \max(\mathbf{O}(N^2), \mathbf{O}(N)) = \mathbf{O}(N^2)$$

$$\mathbf{O}(N) + \mathbf{O}(N) = \mathbf{O}(N + N) = 2 * \mathbf{O}(N) = \mathbf{O}(N)$$

$$\mathbf{O}(N) * \mathbf{O}(N) = \mathbf{O}(N * N) = \mathbf{O}(N^2)$$

$$\mathbf{O}(\mathbf{O}(N)) = \mathbf{O}(N)$$

$$\mathbf{O}(N + N \log N) = \mathbf{O}(N \log N)$$

$$\mathbf{O}(N^2 + 4 * N \log N) = \mathbf{O}(N^2)$$

$$\mathbf{O}(100 + N/2 + 4 * N \log N) = \mathbf{O}(N \log N)$$

Part II

Análisis de la Complejidad

Cálculo complejidad de un algoritmo:

- Evaluar la complejidad de las operaciones que lo componen
- Obtener una expresión de la complejidad genérica que indique cómo aumenta la misma con el volumen de los datos a procesar
 - Normalmente se utiliza Notación asintótica
 - Se suele distinguir distintos casos
- Dos tipos de análisis diferentes:
 - Algoritmos no recursivos
 - Algoritmos recursivos (Cálculo de recurrencias)⁴

⁴Ver cap 4 de Cormen's Book

Complejidad de tiempo usuales

$O(1)$: complejidad constante

Ejecución invariante ante el cambio en número de datos.
(Situación ideal !)

$O(\log(N))$: complejidad Logarítmica

Ejecución escala con el logaritmo del número de datos.

- Es una situación muy deseable correspondiéndose con muchos de los algoritmos óptimos.
- El orden es independiente de la base del logaritmo utilizado:

$$\log_x(N) = \log_x(b) * \log_b(N)$$

Aparece en casos de iteración o recursión no estructura, o bucles cuyo índice evoluciona de forma multiplicativa

Complejidad de tiempo usuales (2)

$O(N)$: complejidad Lineal

Ejecución escala linealmente del número de datos.

- Es una situación muy frecuente

Aparece en bucle simple cuando la complejidad de las operaciones interiores es constante o en algoritmos con recursión estructural (iteraciones con evolución no multiplicativa de los índices)

$O(N \log(N))$: complejidad Lineal-Logarítmica

Ejecución escala como el producto del tamaño de los datos y su logaritmo

- No es una situación infrecuente

Aparece en base a la combinación de una iteración lineal compuesta con un subalgoritmo de complejidad logarítmica en base a iteración o recursión no estructural

Complejidad de tiempo Polinómicas

$O(N^2)$: complejidad cuadrática

Ejecución escala con el cuadrado del número de datos.

Aparece en bucles anidados con iteraciones simples. Ej. Proceso de imágenes

$O(N^3)$: complejidad Cúbica

Ejecución escala con el cubo del número de datos.

Aparece en bucles anidados con iteraciones simples. Ej. Multiplicación de Matrices

$O(N^k)$: complejidad polinómica

Ejecución escala con la potencia del número de datos.

Bucles anidados en general.

Complejidad de tiempo exponencial

$O(c^N)$ $c > 1$: complejidad exponencial

Ejecución escala como una constante elevado a N

Aparece en algoritmos del tipo **Divide y Vencerás** del tipo

$$T(N) = a * T(N/b) + f(N)^a$$

o procesos de forma recursiva del tipo

$$T(N) = a * T(N - 1) + b * T(N - 2) + \dots + f(N)$$

Son algoritmos muy poco eficientes que por su explosión exponencial,
"escalas mal"

Ejemplos: Cálculo de números de Fibonacci, Problemas de planificación temporal.

^aeste tipo de algoritmo también puede dar lugar a complejidades del tipo polinómico, o pol-logarítmico

Evaluando el Orden de complejidad de un algoritmo

En un algoritmo, es un conjunto de operaciones básicas, asignaciones, condicionales de Flujo, iteraciones, y llamadas a otras funciones y llamadas recursivas

- **Operaciones básicas** (+/−, *, /, operaciones matemáticas, etc...) . En tanto operen sobre datos atómicos (no vectores) son rápidas y esencialmente invariante con los datos

Tomaremos $\Rightarrow O(1)$

- **Asignaciones de variables** (=). Su coste sólo depende del tipo de datos y normalmente sólo involucra la asignación de punteros a memoria.

Tomaremos $\Rightarrow O(1)$

- **Secuencias de Operaciones** El coste de ejecución es la suma de los costes de cada operación. Aplicando los criterios de la suma:
 $\Rightarrow O[l_1, l_2, \dots, l_m] = \max[O(l_1), O(l_2), \dots, O(l_m)]$

Evaluando el Orden de complejidad de un algoritmo II

- **Llamadas a funciones** $T(\text{llamada}) = T(\text{ejecutar función})$
Se puede despreciar el tiempo de paso de argumentos si se pasan por referencia
- **Instrucciones Condicionales.** Hay que considerar el tiempo de evaluación de las condiciones (normalmente $\sim O(1)$) más el tiempo de cada posible rama de ejecución

$$O\left(\begin{array}{l} \text{if Cond:} \\ \qquad B1 \\ \text{else:} \\ \qquad B2 \\ \text{End if} \end{array}\right) \Rightarrow \max[O(Cond), O(B1), O(B2)]$$

Evaluando el Orden de complejidad de un algoritmo III

- **Instrucciones iteración:** FOR: `n_iter` o WHILE: `n_iter` con diversos niveles de anidamiento, y aplicado a un bloque de instrucciones depende del iterador que a su vez, depende de los datos (peor caso y mejor caso)
Tomaremos $\Rightarrow O(N^k * \log^j N)$ donde k es el número de anidamientos con iteración estructural y j el número de anidamientos con recursión no estructural
- **Llamadas a funciones:** $T(\text{llamada}) = T(\text{ejecutar función})$
Se puede despreciar el tiempo de paso de argumentos si se pasan por referencia
- **Llamadas Recursivas:** Es necesario evaluar el **Branching Factor** y la **profundidad del árbol de recursión** para evaluar el Orden del Algoritmo (lo veremos más adelante)

Complejidad Polinómica: Ejemplo Multiplicación de Matrices

Sea A y B matrices de dimensiones $n \times m$ y $m \times k$ respectivamente:
Entonces al algoritmo básico de multiplicación: $C = A \times B$ se define como:

$$c_{i,j} = \sum_{s=0}^{s=m-1} a_{i,s} * b_{s,j}$$

Analiza:

- Dónde están las operaciones costosas ??
- Cuántas veces se ejecutan?

La complejidad es $n \times m \times k \sim n^3$ ^a

^aExisten algoritmos que llegan a complejidad $\sim O(n^{2,7})$ Siendo una operación clave, cualquier mejora es importante !!

```
function MATMULT(A,B)
  n, m ← Dimensions of A
  p, k ← Dimensions of B
  if p != m then
    RaiseError (Matrices No congruentes)
  else
    C ← MATALLOC(n,k)
    for i in range(n) do
      for j in range(k) do
        ci,j ← 0
        for s in range(p) do
          ci,j ← ci,j + ai,s * bs,j
        end for
      end for
    end for
  end if
  return C
end function
```

Complejidad Logarítmica: Ejemplo Multiplicación a la Russe

Multiplicación a la rusa

consiste en multiplicar sucesivamente por 2 el multiplicando y dividir por 2 el multiplicador hasta que el multiplicador tome el valor 1. En el proceso, se suman todos los multiplicandos correspondientes a los multiplicadores impares. Dicha suma es el producto de los dos números

Cuál es la complejidad ?

- Cuántos Loops hay ?
 - Uno, el While
- Cuántas veces se ejecuta ?
 - la mitad de $\log_2(m)$
- Cual es el coste de cada ejecución ?
 - Suma de un número de $\log_2(n)$ dígitos más dos bit-shifts

$$\Rightarrow \log_2(n) \times \log_2(m)$$

```
function RUSMULT(n,m)
    res ← 0
    while m ≥ 1 do
        if m is odd then
            res ← res + n
            m ← ⌊m/2⌋ ▷ bit Shift right
            n ← n + n ▷ bit Shift Left
        end if
    end while
    return res
end function
```

Binary Search




Figure: Visualización
Binary Search
©Wikipedia

```
function BINSEARCH(array, low, high,x)
  if high ≥ low then
    mid ← ⌊(high + low)/2⌋
    if array[mid] = x then
      return mid
    else if array[mid] > x then
      return BINSEARCH(arr, low, mid - 1, x)
    else
      return BINSEARCH(arr, mid+1,high, x)
    end if
  else
    return -1
  end if
end function
```

Complejidad equivalente al número de saltos $\sim \log(N)$ contenidos...


Complejidad Lineal-Logarítmica: Ejemplo MergeSort

MergeSort

Divide la secuencia en dos, sobre los que invoca el Merge_sort de forma recursiva, para luego realizar un merge de la secuencias previamente ordenadas

Cuál es la complejidad ?

- Fase de división
 - $\log_2(N) \times O(1)$
- Cuántos niveles hay en el árbol durante el merge ?
 - $\log_2(N)$
- Cuál es el coste de cada uno de ellos
 - $O(N)$
- Cuál es la complejidad resultante ?
 - $\log_2(N) * (O(1) + O(N))$
 - $O(N * \log N)$



$O(2^N)$: complejidad exponencial

Explosión combinatoria

Aparece en algoritmos con recursión en que hay dos llamadas o más por cada dato de entrada

La base es frecuentemente 2, pero puede ser cualquier constante > 1


- Cada llamada genera, recursivamente 2 llamadas.
- La profundidad del árbol de recursión es n
- \Rightarrow **La complejidad es por tanto $\sim O(2^n)$**

```
function FIBONACCI(n)
  if  $n \leq 1$  then
    return n
  else
    return FIBONACCI(n-1) +
           FIBONACCI(n-2)
  end if
end function
```

Complejidad de Algoritmos Recursivos: Método del Árbol de Recursión

- 1 Dibuja el árbol de recursion definido por el algoritmo
- 2 En el árbol de recursión, cada nodo representa el coste de un subproblema aislado dentro del árbol. Evalúa el coste de ejecución del nodo.
- 3 Sumando los costes de cada nodo, en cada nivel de recursión y evaluando la profundidad del árbol, podemos estimar el coste total de la recursión

Tomemos una recursión del tipo: $T(N) = 3T(\lfloor n/4 \rfloor) + \Theta(n^2)$ y veamos el árbol de recursión:




Complejidad de Algoritmos Recursivos: Método del Árbol de Recursión (cont)

- La profundidad del árbol es de $\log_4 n$ en base al **branching factor**
- En el nivel final, hay $3^{\log_4 n} = n^{\log_4 3}$ nodos con coste unitario $\mathbf{O}(1)$
- En los niveles intermedios los costes son de $cn^2 + 3/16cn^2 + (3/16)^2cn^2 + \dots + (3/16)^{\log_4(n-1)}cn^2$

En consecuencia

$$\begin{aligned}T(N) &= \sum_{i=0}^{\log_4 n - 1} (3/16)^i cn^2 + \Theta(n^{\log_4 3}) \\&< \sum_{i=0}^{\infty} (3/16)^i cn^2 + \Theta(n^{\log_4 3}) \\&= \frac{1}{1 - 3/16} cn^2 + \Theta(n^{\log_4 3}) \\&= \frac{16}{3} cn^2 + \Theta(n^{\log_4 3}) = \mathbf{O}(n^2)\end{aligned}$$

Eof Tema 3: Gracias !



Nature is highly fractal and recursive...